

Análisis Factorial con la librería psych

Omar Sanchez Hernandez

4/6/2022

Introduccion

Para la realización del siguiente ejercicio practico se hará uso de la librería ***psych*** que contiene diferentes matrices de datos y herramientas útiles para facilitar la aplicación de estadísticas al área de las ciencias sociales.

Librerías a utilizar

```
library(psych)
library(polycor)
library(ggcorrplot)
library(knitr)
```

Obtención de la matriz de datos

Se carga la matriz de datos **bfi** que se encuentra dentro de la librería **psych**.

```
x <- bfi
```

Exploracion de la matriz

```
dim(x)
```

```
## [1] 2800 28
```

En un principio la matriz de datos contiene 2800 observaciones y 28 variables.

Tipo de las variables contenidas

```
kable(str(x))
```

```
## 'data.frame':    2800 obs. of  28 variables:
## $ A1      : int  2 2 5 4 2 6 2 4 4 2 ...
## $ A2      : int  4 4 4 4 3 6 5 3 3 5 ...
## $ A3      : int  3 5 5 6 3 5 5 1 6 6 ...
## $ A4      : int  4 2 4 5 4 6 3 5 3 6 ...
## $ A5      : int  4 5 4 5 5 5 5 1 3 5 ...
## $ C1      : int  2 5 4 4 4 6 5 3 6 6 ...
## $ C2      : int  3 4 5 4 4 6 4 2 6 5 ...
## $ C3      : int  3 4 4 3 5 6 4 4 3 6 ...
## $ C4      : int  4 3 2 5 3 1 2 2 4 2 ...
## $ C5      : int  4 4 5 5 2 3 3 4 5 1 ...
## $ E1      : int  3 1 2 5 2 2 4 3 5 2 ...
## $ E2      : int  3 1 4 3 2 1 3 6 3 2 ...
## $ E3      : int  3 6 4 4 5 6 4 4 NA 4 ...
## $ E4      : int  4 4 4 4 4 5 5 2 4 5 ...
## $ E5      : int  4 3 5 4 5 6 5 1 3 5 ...
## $ N1      : int  3 3 4 2 2 3 1 6 5 5 ...
## $ N2      : int  4 3 5 5 3 5 2 3 5 5 ...
## $ N3      : int  2 3 4 2 4 2 2 2 2 5 ...
## $ N4      : int  2 5 2 4 4 2 1 6 3 2 ...
## $ N5      : int  3 5 3 1 3 3 1 4 3 4 ...
## $ O1      : int  3 4 4 3 3 4 5 3 6 5 ...
## $ O2      : int  6 2 2 3 3 3 2 2 6 1 ...
## $ O3      : int  3 4 5 4 4 5 5 4 6 5 ...
## $ O4      : int  4 3 5 3 3 6 6 5 6 5 ...
## $ O5      : int  3 3 2 5 3 1 1 3 1 2 ...
## $ gender   : int  1 2 2 2 1 2 1 1 1 2 ...
## $ education: int  NA NA NA NA NA 3 NA 2 1 NA ...
## $ age      : int  16 18 17 17 17 21 18 19 19 17 ...
```

```
|| || || ||
```

Se puede observar que todas las variables presentes son de tipo entero y que además existe la presencia de valores ausentes (NA).

Nombre de las variables

```
colnames(x)
```

```
## [1] "A1"      "A2"      "A3"      "A4"      "A5"      "C1"
## [7] "C2"      "C3"      "C4"      "C5"      "E1"      "E2"
## [13] "E3"      "E4"      "E5"      "N1"      "N2"      "N3"
## [19] "N4"      "N5"      "O1"      "O2"      "O3"      "O4"
## [25] "O5"      "gender"  "education" "age"
```


Sub matriz de datos

```
x1<-bfi[1:200,1:25]
```

Se procedió a obtener un subconjunto del total de datos para trabajar.

Matriz de correlaciones

```
R<- hetcor(x1)$correlations
ggcorrplot(R, hc.order= TRUE)
```



Haciendo uso del gráfico que representa la matriz de correlaciones es que podemos darnos una idea respecto a si es viable aplicar el análisis factorial debido a que las variables entre si presentan correlaciones.

Pruebas sobre la matriz de correlaciones

Se utiliza la prueba de esfericidad de Bartlett para probar que estadísticamente la matriz de correlaciones es distinta a la matriz identidad de tamaño \mathbf{n} ,

```
prueba_Bartlett<- cortest.bartlett(R)
prueba_Bartlett
```

```
## $chisq
## [1] 891.1536
##
## $p.value
## [1] 5.931663e-60
##
```

```
## $df
## [1] 300
```

Se encontro un p-valor menor a 0.001 por lo que se rechaza la hipotesis nula y se concluye que la matriz de correlaciones es distinta a la matriz de identidad.

Criterio Kaiser-Meyer-Olkin

Permite identificar si los datos que se van a analizar son adecuados para un análisis factorial.

0.00 a 0.49 No adecuados 0.50 a 0.59 Poco adecuados 0.60 a 0.69 Aceptables 0.70 a 0.89 Buenos 0.90 a 1.00 Excelente

KMO(R)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.76
## MSA for each item =
##   A1  A2  A3  A4  A5  C1  C2  C3  C4  C5  E1  E2  E3  E4  E5  N1
## 0.66 0.77 0.69 0.73 0.75 0.74 0.79 0.76 0.76 0.74 0.80 0.81 0.79 0.81 0.83 0.70
##   N2  N3  N4  N5  O1  O2  O3  O4  O5
## 0.67 0.82 0.79 0.82 0.79 0.65 0.81 0.62 0.77
```

El indice KMO resulta de 0.76 por lo que es un buen indicador sobre los datos para continuar con el analisis factorial.

Extracción de factores

Para la extraccion de factores se pueden usar varios metodos que los calculan de diferentes maneras pero para el caso de este desarrollo de opta por el metodo de maxima verosimilitud (**mle**) y por el metodo del minimo residuo (**minres**).

Metodo de Maxima Verosimilitud

```
modelo1<- fa(R,nfactor=3,rotate = "none",fm = "mle")
```

Metodo del minimo residuo

```
modelo2<- fa(R,nfactor=3,rotate = "none",fm = "minres")
```

Extraer el resultado de las Comunalidades, allí se encuentra la proporción de varianza explicada. Se interpreta de tal forma que números cercanos a 1 están bastante bien explicadas por los factores comunes, entre más comunalidades altas aya en el factor este explica mejor la variable y el análisis en consecuencia será mejor.

```
C1<-sort(modelo1$communality,decreasing = TRUE)
C2<-sort(modelo2$communality,decreasing = TRUE)
```

combinar los resultados para comparar

```
head(cbind(C1,C2))
```

```
##           C1           C2
## N1 0.7576920 0.6809294
## E2 0.6802809 0.6564523
## N2 0.6797943 0.5866483
## E1 0.5219674 0.5394762
## N3 0.5198285 0.4942059
## N4 0.4839516 0.4744005
```

Extracción de unidades: La unicidad es el cuadrado del coeficiente del factor único, y se expresa como la proporción de la varianza explicada por el factor único. es decir, no puede ser explicada por otros factores.

Probar la unicidad del primer modelo

```
u1<- sort(modelo1$uniquenesses,decreasing = TRUE)
```

Probar la unicidad del segundo modelo

```
u2<- sort(modelo2$uniquenesses,decreasing = TRUE)
```

Comparacion de ambas unicidades

```
head(cbind(u1,u2))
```


```
##           u1           u2
## O2 0.9460554 0.9293483
## A4 0.8928892 0.8908844
## A1 0.8607240 0.8822080
## O5 0.8533481 0.8272041
## C5 0.8136600 0.7931685
## O1 0.7986908 0.7904667
```

Al observar la unicidad de los dos métodos de rotación resulta que la variación entre ellas es muy pequeña y no cambia mucho una de la otra. La unicidad es el cuadrado del coeficiente del factor único, que expresa la proporción de la varianza que queda explicada por el factor único, es decir, la varianza que no puede explicarse por los factores comunes.

Se considera rotar por Máxima Verosimilitud o Mínimo residuo la varianza que no se puede explicar. Los coeficientes resultan ser muy parecidos y queda en decisión del investigador cual es el método que más conveniente para llegar a una conclusión.

Seleccionar el numero de factores

```
scree(R)
```





En el Scree plot podemos escoger la cantidad de factores a utilizar, además de que en este gráfico tenemos dos opciones por las cuales podemos inclinarnos: el método de **Componentes Principales (PC)** y **Análisis Factorial (FA)**. En los componentes principales la cantidad de factores que seleccionamos es hasta donde se forme un codo.


Observamos que los dos métodos nos limitan a usar la misma cantidad de factores pues la gráfica de cada uno no discrepa tanto uno del otro.

Rotación de la matriz

```
library(GPARotation)
rot<-c("None", "Varimax", "Quartimax", "Promax")
bi_mod<-function(tipo){
  biplot.psych(fa(x1, nfactors = 2,
    fm= "minres", rotate=tipo),
    main = paste("Biplot con rotación", tipo),
    col=c("#FFB6C1", "#87CEFA", "#87CEFA"), pch=c(21,18), group=bfi[, "gender"])
}
sapply(rot, bi_mod)
```








```
## $None
## NULL
##
## $Varimax
## NULL
##
## $Quartimax
## NULL
##
## $Promax
## NULL
```

Gráfico de arbol

Para observar cuales variables se asocian a cual factor es que se hace uso del siguiente gráfico:

```
modelo_varimax<-fa(R,nfactor = 5,
                  rotate = "varimax",
                  fm="minres")
fa.diagram(modelo_varimax)
```

Factor Analysis



Lineas rojas son cargas positivas y lineas negras cargas negativas

Visualización de la matriz de carga rotada.

```
print(modelo_varimax$loadings, cut=0)
```

```
##
## Loadings:
##      MR1    MR2    MR4    MR3    MR5
## A1  0.234  0.106 -0.422 -0.072 -0.092
## A2  0.112 -0.032  0.653  0.190  0.113
## A3  0.198  0.066  0.744  0.051  0.169
## A4  0.163 -0.048  0.413  0.137 -0.142
## A5  0.328 -0.154  0.692 -0.009  0.115
## C1  0.054  0.089  0.140  0.634  0.287
## C2  0.052  0.174  0.114  0.690  0.050
## C3  0.032  0.018  0.076  0.642  0.016
## C4 -0.058  0.087 -0.090 -0.559 -0.159
## C5 -0.241  0.228 -0.040 -0.459  0.014
## E1 -0.691 -0.006 -0.066 -0.084 -0.017
## E2 -0.713  0.345 -0.138 -0.133 -0.025
## E3  0.546  0.003  0.157 -0.008  0.221
## E4  0.522 -0.027  0.416  0.167  0.048
## E5  0.588 -0.009  0.148  0.308  0.159
## N1  0.131  0.802 -0.150 -0.074 -0.133
## N2  0.088  0.800 -0.151 -0.038 -0.008
## N3 -0.183  0.701  0.005  0.037 -0.087
```

```

## N4 -0.513  0.491 -0.006  0.004  0.034
## N5 -0.274  0.571  0.059  0.096 -0.082
## 01  0.203 -0.107  0.148  0.076  0.535
## 02 -0.099  0.096  0.144 -0.191 -0.330
## 03  0.326 -0.159  0.034  0.062  0.680
## 04 -0.240  0.122  0.169  0.105  0.548
## 05 -0.004  0.061 -0.074 -0.077 -0.636
##
##
##          MR1   MR2   MR4   MR3   MR5
## SS loadings    2.823 2.667 2.223 2.103 1.867
## Proportion Var 0.113 0.107 0.089 0.084 0.075
## Cumulative Var 0.113 0.220 0.309 0.393 0.467

```